Kausaalne hindamine: John Snow kooleraauuring

Steven Sepp ja Mark Sverker Saar

2026

1. Uurimisprobleem

- **Taust:** 19. sajandi keskel Londonis levis koolera. Põhjuseks peeti halba õhku (miasmi teooria).
- **Hüpotees (John Snow):** Koolera levib hoopis saastunud vee kaudu.
- **Sekkumine:** 1852. aastal kolis Lambethi vee-ettevõte oma veevõtukoha Londonist ülesvoolu (puhtam vesi). S&V ettevõte jättis veevõtukoha saastunud piirkonda.
- **Eesmärk:** Hinnata puhta vee ("sekkumine") kausaalset mõju koolerasurmadele piirkonnas.

2. Kausaalse identifitseerimise strateegia (DID)

- **Meetod:** Erinevused-erinevustes (Difference-in-Differences, DID).
- **Mõjugrupp (Treated):** Lambethi piirkond (sai alates 1854 puhta vee).
- **Kontrollgrupp (Control):** S&V piirkond (jäi saastunud veele).
- **Aeg (Post):** 1849 (enne) vs 1854 (pärast).
- **Väljund (Outcome):** Koolerasurmad 10 000 elaniku kohta.
- **Eeldus:** Ilma veevõtukoha kolimiseta oleks suremuse muutus olnud mõlemas piirkonnas sarnane (paralleelsed trendid).

3. Kausaalne mudel ja DAG

- Sekkumine (puhtam vesi) on otsene põhjus suremuse vähenemisele.
- Aeg ja Piirkond määravad veevõtukoha puhtuse ja võivad mõjutada ka üldist suremuse taset.

DAG struktuur: Piirkond $\rightarrow$ Vesi $\rightarrow$ Suremus Aeg $\rightarrow$ Vesi Aeg $\rightarrow$ Suremus Piirkond $\rightarrow$ Suremus

4. Kirjeldav statistika ja trendid

(Lisage siia esitlust tehes R-st saadud koolerasuremuse DID joonis `koolerasuremus_did.pdf`)

- 1849. aastal oli suremus mõlemas grupis väga sarnane (~130-135 surma).
- 1854. aastaks tõusis suremus kontrollgrupis veidi (kuni 146,6).
- Mõjugrupis langes suremus aga drastiliselt (84,9 peale).

5. Regressioonitulemused (DID hinnang)

DID mudeli valem:

$$Deathrate = \beta_0 + \beta_1 Post + \beta_2 Treated + \beta_3 (Post \times Treated)$$

- **Tulemus:** $\beta_3 = -56,9$
- **Tõlgendus:** Puhta vee pakkumine hoidis hinnanguliselt ära 56,9 surmajuhtumit 10 000 inimese kohta.

6. Järeldused ja usaldusväärsus

- **Järeldus:** Tulemus toetab tugevalt Snow hüpoteesi – koolerat levitas saastunud vesi.
- **Usaldusväärsus:**
  - Analüüs tugineb agregeeritud andmetel (4 andmepunkti), seega p-väärtusi ei saa standardmudeliga leida.
  - Kuid kausaalse meetodi (DID) loogika ja suur efekti suurus muudavad tulemuse praktilises mõttes väga usutavaks.
  - Paralleelsete trendide eeldus on ajaloolises kontekstis hästi põhjendatud.